

# Laboratory 6: Segmentation

Fabian Martínez  
Universidad de los Andes  
Bogota

fe.martinez10@uniandes.edu.co

Juan Felipe Pérez  
Universidad de los Andes  
Bogota

jf.perez10@uniandes.edu.co

## Abstract

*En el siguiente informe se presentan los procesos y resultados obtenidos al realizar la segmentación de imágenes utilizando cuatro algoritmos diferentes.*

## 1. Introducción

Uno de los grandes problemas en los problemas relacionados a la visión en computador corresponde a la segmentación de una imagen, con el fin de representarla de una manera más significativa y más fácil para realizar un posterior análisis.

Este proceso de segmentación tiene como objetivo el dividir una imagen en varias partes que tengan características comunes, o, en lo posible, que pertenezcan a cierta clase de objetos de interés. De manera general, no existe un único método estándar que permita realizar una segmentación perfecta para todo tipo de imágenes, por lo tanto es necesario probar diversas formas de segmentación para llegar de manera óptima al resultado deseado dependiendo de la aplicación a la cual se quiere llegar. Junto con la gran diversidad de métodos que existen para realizar el proceso de segmentación, existe una gran cantidad de métodos para evaluar la calidad de la segmentación.

Entre las principales aplicaciones que tienen estos problemas de segmentación son la detección de objetos en imágenes satélite, el reconocimiento de caras y de iris, diferenciación por medio de huellas digitales e incluso en el ámbito de la medicina en los cuales se espera por medio del análisis de imagen una correcta localización de tumores y de patologías, cirugías guiadas por un ordenador, diagnósticos de enfermedades, estudio de estructuras anatómicas y muchas otras más.

### 1.1. Objetivos

- Realizar la segmentación de imágenes por medio de 4 métodos diferentes: k-means, watersheds, jerárquica y gmm.

- Comparar la eficiencia de segmentación de los diferentes métodos implementados incluyendo variables como tiempo y memoria utilizados.
- Proponer un método de evaluación adecuado para los resultados obtenidos con la segmentación de las imágenes con las anotaciones presentadas.

## 2. Materiales y métodos

Para la realización de la segmentación se realizó una función con 4 parámetros, los cuales eran el tipo de espacio de color en el que se quería trabajar (ya fuera rgb, lab o hsv, y si se quería tener en cuenta la información espacial), el tipo de método con el cual se quería segmentar la imagen, el número de clusters y finalmente la imagen a la que se le va a realizar la segmentación.

### 2.1. Información Espacial

Debido a que uno de los parámetros contiene las siglas +xy, estas hacen referencia a que se debe tener en cuenta la información espacial de los píxeles en la imagen para realizar la segmentación. Para incluir esta información espacial se crean "dos dimensiones adicionales" de la imagen además de los canales del respectivo espacio de color utilizado para la segmentación. En estas dos matrices se presenta la información espacial de la siguiente manera:

- Información de X: La matriz tiene enumerados las posiciones desde 1 hasta el tamaño de la imagen, de esta manera la primera columna de la matriz es un vector de 1, la siguiente un vector de 2 y así sucesivamente.
- Información de Y: Similar a la matriz anterior, sin embargo los valores cambian en las filas de la matriz.

Los métodos utilizados se detallan a continuación.

### 2.2. K-Means

Este método es un método de cuantización de vectores, el cual tiene como ventaja su simplicidad. Debido a que este

método trabaja con vectores es necesario realizar una transformación de la imagen en vectores. Esta transformación se realiza por medio de una concatenación de la información presentada en los diferentes canales del espacio de color así como de la información espacial (opcional).

El algoritmo inicia con un grupo inicial de centroides al azar, asigna cada píxel (vector con las características) al centroide mas cercano e itera los centroides hasta que no cambie la solución obtenida. Para realizar este procedimiento Matlab cuenta con la función `kmeans`, la cual recibe una matriz `mx1` y `k` clusters en los que se quieren agrupar. Una vez obtenida la matriz solución, se reconstruye de nuevo la imagen con las etiquetas correspondientes a cada cluster.

### 2.3. Mezcla de Gaussianas (GMM)

Para este método se tiene nuevamente la entrada de la matriz, similar a la de `k-means`. Sin embargo, se utiliza la función `fitgmdist` de matlab, la cual es una función que busca encontrar una mezcla de distribuciones gaussianas con las cuales pueda explicarse la distribución que presentan los datos. Debido a que los resultados son unas distribuciones de probabilidad, es necesario realizar una clusterización fuerte para separar los datos en segmentos.

### 2.4. Jerárquico

Para este método es necesario redimensionar la imagen. Inicialmente se toman los diferentes canales de la imagen y se concatenan, formando una matriz. Luego con la función `pdist` de Matlab es posible encontrar la distancia entre todos los posibles pares de objetos (de aquí que la cantidad de memoria necesaria es un factor fundamental para el método) y posteriormente con la función `linkage` se logra crear un árbol de agrupamiento de acuerdo a las distancias obtenidas anteriormente. Luego se clusteriza cortando este árbol generando la imagen segmentada.

### 2.5. Watersheds

Este método se basa en la imposición de mínimos en una imagen manteniendo unos marcadores, los cuales son definidos de acuerdo al gradiente que presenta la función. Esta función agrupa las regiones de la imagen y da como resultado los bordes más relevantes de la imagen.

### 2.6. Base de Datos

La base de datos de las imágenes se compone de un total de 8 imágenes, tomadas de la base de datos BSDS, en las cuales se presenta un archivo con las anotaciones de bordes realizadas por humanos.

### 2.7. Espacios de color y comentarios adicionales

Para la segmentación de las imágenes se utilizaron tres espacios de color: el primero corresponde a RGB, el se-

gundo corresponde a Lab y el tercero a HSV. Como ya se nombró anteriormente, en caso de querer tener en cuenta la información espacial se utiliza la etiqueta `+xy`. Es necesario realizar algunos comentarios respecto a los métodos utilizados.

- Para realizar el proceso de segmentación jerárquica es necesario realizar un redimensionamiento de la imagen a un tamaño menor. Este procedimiento es necesario debido a la alta capacidad de memoria que requiere la ejecución del método. Debido a la necesidad de reescalamiento de la imagen, se pierde una gran cantidad de información respecto a las altas frecuencias lo que da como resultado que algunos bordes sean indetectables, y al volver al tamaño original de la imagen segmentada esta este limitada por regiones rectangulares (efecto de pixelación).
- Debido a que no es posible realizar Watersheds en los tres canales y obtener una respuesta objetiva, se decide por utilizar un único canal para realizar la segmentación. La elección del canal no se realiza de manera aleatoria, sino que se evalúa la varianza presentada en cada uno de los píxeles de los diferentes canales y se elige como canal de análisis aquel en el que el valor de la varianza es mayor. Se decidió realizar esta selección debido a que la segmentación en algunas imágenes de prueba del método la que mejor tenía un resultado era la que tenía una mayor varianza.

### 2.8. Número de clusters

La selección del número de clusters es un parámetro de . Para tener un óptimo número de clusters es necesario tener un conocimiento previo de la imagen que se va a segmentar a continuación. Para poder realizar unos resultados comparables en la etapa de evaluación, se toma como parámetro a cada una de las imágenes el número máximo que se presentan en las anotaciones seleccionadas para cada imagen.

### 2.9. Evaluación

Para la evaluación de la segmentación se dividen los métodos en dos categorías:

1. `Kmeans`, `Gmm` y jerárquica: Se decide que la evaluación de los métodos se realiza por medio del índice de jaccard, es decir, obteniendo un porcentaje de superposición de las áreas involucradas en las anotaciones y las de el resultado de nuestros métodos.
2. `Watersheds`: Debido a que el resultado con la segmentación por `watersheds` da como resultado los bordes, se decide que la mejor forma de evaluación de este método es por medio de una toma de datos de precisión y cobertura para cada una de las imágenes. Esto se realiza con la información de los bordes que obtenemos

en la segmentación con watersheds al ser comparada píxel a píxel con las anotaciones en las que se sabe de la existencia de un borde.

### 3. Resultados

A continuación se presentan los resultados obtenidos en los métodos de segmentación.

Como primera medida, se presenta un ejemplo de segmentación a una imagen original, la cual se observa en la siguiente figura.



Fig. 1. Imagen original




Fig. 2. Imágenes obtenidas en la segmentación por kmeans




Fig. 3. Imágenes obtenidas en la segmentación con gmm

Debido a la complejidad obtenida en las anteriores imágenes, se realiza nuevamente una segmentación para diferentes imágenes las cuales se pueden observar a continuación.

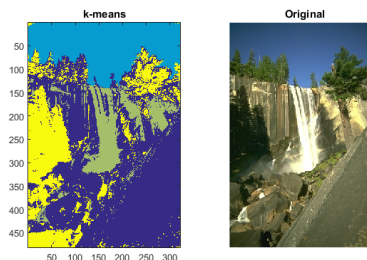


Fig. 4. Imagen segmentada con K-means




Fig. 5. Imagen segmentada con gmm




Fig. 6. Imagen segmentada jerárquicamente




Fig. 7. Imagen segmentada con watersheds

#### 3.1. Resultados de evaluación

En primer lugar se presentan los índices de jaccard para la segmentación con k-means. En este vector se observan los resultados para cada uno de los posibles espacios de representación.

```
>> jaccards2

jaccards2 =

    0.4889
    0.4626
    0.4860
    0.4289
    0.5074
    0.4598
```

Fig. 8. Resultados de índices de jaccard en K-means

Se presentan igualmente

```
>> jaccards2(:,3)

ans =

    0.0776
    0.0776
    0.0471
    0.0471
    0.0477
    0.0477
```

Fig. 9. Resultados de índices de jaccard en la segmentación jerárquica

Finalmente se presenta la curva de PR, contruida con la segmentación de una imagen por medio del método de Watersheds.




Fig. 10. Curva de P-R para watersheds

## 4. Discusión

Respecto a los primeros resultados, cabe resaltar que se presentan unas notables diferencias entre los diferentes espacios de representación del color, es decir, tener en cuenta los espacios RGB lab y hsv puede tener resultados diferentes en el momento de realizar una segmentación de imagen. Estas diferencias se producen ya que la matriz que describe las características de la imagen cambia al realizarse

la transformación entre los espacios y por lo tanto la clusterización no es semejante.

El mejor método, en términos de simplicidad y de implementación, así como también de resultados fue el de k-means, especialmente cuando la cantidad de clusters son pequeños, y son aún mejores cuando se incluye la información espacial, ejemplo que se observa al final del documento.

Por otra parte, el lograr tener una mayor importancia (o menor) en algunos de los canales de color permite tener diferencias en la clusterización. Sin embargo, esta puede ser un arma de doble filo ya que puede que en algunas imágenes se tenga una mayor información en cierto canal, mientras que en otras imágenes la información más relevante se presente en otro canal.

## 5. Conclusiones

1. EL proceso de segmentación de una imagen requiere una gran cantidad de tiempo y de recursos computacionales.
2. Existen diversos métodos para la segmentación de imágenes, cada uno de ellos tiene sus propias ventajas y desventajas en términos de resultados, tiempo, segmentación, simplicidad de implementación, etc.
3. El método de segmentación apropiado depende de las aplicaciones y del objetivo de la segmentación, ya que ciertos métodos pueden funcionar mejor para cierto tipo de imágenes que para otras.

## References

- [1] Martín, M (2004). Técnicas clásicas de Segmentación de Imagen. Laboratory of Mathematics in Imaging. Tomado de [http : //lmi.bwh.harvard.edu/papers/pdfs/2003/martin - fernandezCOURSE03b.pdf](http://lmi.bwh.harvard.edu/papers/pdfs/2003/martin-fernandezCOURSE03b.pdf)
- [2] Munoz, J. Departamento de Lenguajes y Ciencias de La Computación. Universidad de Málaga. Tomado de [http : //www.lcc.uma.es/ munozp/documentos/procesamiento \\_de\\_imagenes/temas/pi\\_cap6.pdf](http://www.lcc.uma.es/munozp/documentos/procesamiento_de_imagenes/temas/pi_cap6.pdf)
- [3] Funciones de Matlab (kmeans, watersheds, etc). Tomadas de [https : //es.mathworks.com/](https://es.mathworks.com/)

## 6. Anexo

Ejemplo donde se presenta la importancia de la información espacial en la clusterización de k-means. La primera no incluye la información, mientras que en la segunda si se tiene en cuenta.



Fig. 11. Segmentación sin información espacial



Fig. 12. Segmentación con información espacial